
Data science et intelligence artificielle au service de la performance opérationnelle en santé prévoyance

*De l'analyse d'enquêtes clients à la détection de comportements atypiques,
en passant par l'exploitation des verbatims par IA générative*

Adja Djénéba Massé COULIBALY

Rapport de mission en alternance — Année universitaire 2025 2026

PROBLÉMATIQUE

Dans quelle mesure la data science, appliquée aux données structurées et non structurées, permet-elle d'améliorer la performance opérationnelle dans le secteur de la santé prévoyance ?

Entreprise d'accueil

Diot-Siaci

Mission : Data Science & IA

Encadrants

Académique : Emmanuel FLACHAIRE

Entreprise : Serigne FALL

Juillet 2026

NON-PLAGIARISM UNDERTAKING

I, (full name of the undersigned) Coulibaly Adja Djeneba Masse

declare being fully aware that plagiarism by copying documents or a portion of a document published in all forms and media, including online publications, constitutes copyright infringement and related rights, as well as outright fraud.

Consequently, I hereby undertake to quote all sources and authors that I've used to write my internship report and its appendices.

Date: 20/08/2026

Signature:



Remerciements

Ce rapport est l'aboutissement d'un parcours exigeant, rendu possible grâce à l'amour, au soutien et à la confiance de nombreuses personnes à qui je souhaite adresser mes plus sincères remerciements.

Je pense en premier lieu à ma famille, pilier indéfectible de ma vie. À ma mère, dont les sacrifices innombrables ont tracé le chemin que j'emprunte aujourd'hui, c'est grâce à elle que je suis là où je suis. À mon père, pour sa présence précieuse et son soutien constant. À toute ma famille, pour l'énergie et l'amour qu'elle m'a transmis tout au long de ce parcours.

À mon binôme, merci pour ta présence au quotidien, ton soutien sans faille et ta patience dans les moments les plus intenses de cette année. Tu as été mon ancre.

Je remercie chaleureusement mon tuteur entreprise, **Serigne FALL**, pour sa bienveillance, sa disponibilité et la confiance qu'il m'a accordée tout au long de cette alternance. Mes remerciements vont également à l'ensemble de mes collègues du pôle data science de Diot-Siaci, pour leur bienveillance, leur générosité et la confiance qu'ils m'ont témoignée dès le premier jour.

À mon tuteur académique, **Emmanuel FLACHAIRE**, merci pour ses conseils éclairés, sa disponibilité et son accompagnement tout au long de ce Master.

Je tiens également à remercier **Badih GHATTAS** et **Pierre MICHEL**, responsables de la filière, pour avoir cru en moi et m'avoir offert l'opportunité d'intégrer ce Master. Leur confiance a été une source de motivation permanente.

À ma meilleure amie et à tous mes amis, merci pour ces nuits passées à mes côtés, pour votre écoute, vos encouragements et votre présence dans les moments de doute comme dans les moments de joie.

Enfin, je me remercie moi-même pour la persévérance, le courage et la détermination dont j'ai fait preuve pour me battre pour mes ambitions et ne jamais abandonner. Ce diplôme est aussi le fruit de ma propre volonté.

Table des matières

Glossaire	6
Introduction	9
1 Contexte et enjeux	11
1.1 Présentation de Diot-Siaci et de l'offre PSFI	11
1.1.1 Le groupe Diot-Siaci	11
1.1.2 L'offre Protection Sociale France et Internationale (PSFI)	11
1.1.3 Le pôle data science et mon poste	11
1.2 La satisfaction client dans le secteur de la protection sociale	12
1.2.1 Les indicateurs de satisfaction	12
1.2.2 Les limites des données structurées et l'apport des verbatims	13
1.3 L'intelligence artificielle au service de l'analyse textuelle	13
1.3.1 Le traitement automatique du langage naturel	13
1.3.2 Les grands modèles de langage (LLM)	13
2 Mission 1 : Analyse des comportements de non adhésion à une mu- tuelle collective	15
2.1 Contexte et objectifs de la mission	15
2.2 Facteurs facilitants et obstacles rencontrés	15
2.2.1 Facteurs facilitants	15
2.2.2 Obstacles rencontrés	16
2.3 Préparation et traitement des données avec Alteryx	16
2.3.1 Nettoyage des données	16
2.3.2 Transformations appliquées	16
2.3.3 Justification du choix d'Alteryx	16
2.4 Construction des tableaux de bord sous Tableau	17
2.4.1 Indicateurs retenus	17
2.4.2 Choix des visualisations	17
2.5 Principaux enseignements et recommandations	18
2.5.1 Frein numéro 1 : la méconnaissance du contrat	18
2.5.2 Frein numéro 2 : concurrence et perception du prix	19
2.5.3 Recommandations formulées	19
3 Mission 2 : Analyse sémantique des verbatims clients par l'IA	20
3.1 Origine du besoin et contexte de la mission	20
3.2 Facteurs facilitants et obstacles rencontrés	20

3.2.1	Facteurs facilitants	20
3.2.2	Obstacles rencontrés	21
3.3	Pourquoi le NLP classique ne suffisait pas	21
3.4	Architecture technique de la solution	22
3.4.1	Choix technologiques	22
3.4.2	Ingestion et préparation des fichiers	23
3.5	Conception des prompts et taxonomie thématique	23
3.5.1	Approche par prompt engineering	23
3.5.2	Taxonomie thématique par type d'enquête	24
3.6	Analyse de sentiment	25
3.7	Livrable : l'application Streamlit	25
3.7.1	Fonctionnalités de l'application	25
3.7.2	Choix de conception orientés utilisateur	26
3.8	Résultats et apports pour les métiers	26
3.9	Limites et perspectives	27
4	Mission 3 : Détection automatisée de comportements atypiques sur les décomptes de remboursement santé	28
4.1	Contexte et enjeux de la mission	28
4.2	Facteurs facilitants et obstacles rencontrés	28
4.2.1	Facteurs facilitants	28
4.2.2	Obstacles rencontrés	29
4.3	Pourquoi une approche multi méthodes est nécessaire	29
4.4	La famille Fréquence : trois méthodes statistiques complémentaires	30
4.4.1	Méthode 1 : Détection statistique par Z score	30
4.4.2	Méthode 2 : Analyse des variations temporelles	30
4.4.3	Méthode 3 : Analyse du ratio actes par patient	31
4.4.4	Complémentarité des trois méthodes	31
4.5	Vue d'ensemble des trois familles d'approches	32
4.6	Innovation méthodologique : le scoring de convergence	32
4.6.1	Le constat à l'origine de la démarche	32
4.6.2	L'intuition centrale	32
4.6.3	Pondération exponentielle	33
4.6.4	Normalisation par la taille du professionnel	33
4.7	Architecture technique de la solution	33
4.8	Du score technique au livrable métier	34
4.9	Résultats et apports pour les métiers	34
4.10	Limites et perspectives	35

Conclusion	37
Bibliographie	40
Annexes	41
Annexe A : Architecture technique (Mission 2)	42
Annexe B : Application Streamlit (Mission 2)	43
Annexe C : Tableau de bord Tableau (Mission 1)	47
Annexe D : Workflow Alteryx de préparation (Mission 1)	50
Annexe E : Taxonomie complète (Mission 2)	53
Annexe F : Scoring de convergence (Mission 3)	55
Annexe G : Exemple de livrable (Mission 3)	60
Annexe H : Exemples de verbatims (Mission 2)	62

Glossaire

Terme	Définition
<i>Le monde de la protection sociale</i>	
PSFI	Protection Sociale France et Internationale, la division de Diot-Siaci qui accompagne les entreprises dans leurs contrats santé, prévoyance et retraite.
Courtage	Métier consistant à faire l'intermédiaire entre les assureurs, les entreprises clientes et les assurés, pour concevoir et suivre leurs contrats.
Adhésion	Le fait, pour une personne, de souscrire à un contrat de protection sociale.
Mutuelle collective	Contrat d'assurance santé souscrit par une entreprise ou une association au bénéfice de ses salariés ou de ses membres.
Garanties	Ensemble des prestations couvertes par un contrat d'assurance (soins remboursés, plafonds, etc.).
Tiers payant	Dispositif qui évite à l'assuré d'avancer les frais de santé chez le professionnel de santé.
Décompte	Détail d'une demande de remboursement traitée par l'assureur pour un assuré.
Professionnel de santé conventionné	Praticien (opticien, pharmacien, médecin, etc.) ayant signé un accord avec les organismes d'assurance.
<i>Écouter la voix du client</i>	
Verbatim	Réponse libre écrite par un client dans une enquête de satisfaction, exprimée avec ses propres mots.
Enquête à chaud	Questionnaire envoyé peu après une interaction client, pour recueillir un ressenti immédiat.
Enquête à froid	Questionnaire envoyé plus tard, pour recueillir un retour réfléchi sur l'expérience globale.
NPS	Indicateur mesurant la probabilité qu'un client recommande le service à son entourage.

(suite page suivante)

Glossaire (suite)

Terme	Définition
CSAT	Indicateur mesurant la satisfaction globale d’un client suite à une interaction.
CES	Indicateur mesurant l’effort que le client a dû fournir pour obtenir une réponse ou résoudre son problème.

Data science et intelligence artificielle

Data science	Discipline qui exploite les données pour en tirer des connaissances et des décisions.
Intelligence artificielle générative	Technologie capable de produire du contenu (texte, analyse) en comprenant le langage humain.
LLM	Grand modèle de langage, capable de comprendre et d’analyser un texte comme le ferait un humain (ex. Mistral).
NLP	Traitement automatique du langage naturel, ensemble des techniques permettant à une machine d’analyser du texte.
Analyse de sentiment	Détection automatique de la tonalité d’un texte (positif, négatif, neutre, mixte).
Comportement atypique	Activité d’un professionnel de santé qui s’écarte fortement des normes habituelles observées.
Validation croisée	Démarche consistant à croiser plusieurs méthodes indépendantes pour fiabiliser une détection.

Outils utilisés au quotidien

Snowflake	Plateforme dans le cloud qui centralise et permet d’exploiter de grands volumes de données.
Mistral Large 2	Grand modèle de langage utilisé pour l’analyse des verbatims dans la Mission 2.
Alteryx	Logiciel de préparation et d’automatisation des traitements de données, sans écrire de code.
Tableau	Logiciel de création de tableaux de bord interactifs pour visualiser les données.
Tableau de bord	Interface visuelle synthétisant plusieurs indicateurs et graphiques sur une même vue.

(suite page suivante)

Glossaire (suite)

Terme	Définition
Streamlit	Outil permettant de créer facilement des applications web à partir de code Python.
Python	Langage de programmation largement utilisé en data science.

Introduction

Le secteur du courtage en assurance traverse une transformation profonde, portée par la massification des données et l'essor de l'intelligence artificielle. Longtemps structurés autour d'expertises en conseil, négociation et gestion de contrats, les courtiers doivent désormais composer avec une nouvelle matière première : la donnée client, produite en continu par les parcours d'adhésion, les remboursements, les interactions avec les services et les retours qualitatifs exprimés à travers les enquêtes de satisfaction. Cette transformation est particulièrement sensible dans le domaine de la **santé et de la prévoyance**, où la qualité du service rendu à l'assuré devient un facteur de différenciation aussi déterminant que la compétitivité tarifaire des garanties négociées auprès des assureurs. L'émergence récente des grands modèles de langage ouvre par ailleurs des perspectives nouvelles pour exploiter des données jusqu'alors difficiles à traiter à grande échelle, notamment les retours qualitatifs des assurés.

C'est dans ce contexte que s'inscrit mon alternance en **Data Science et Intelligence Artificielle** au sein du pôle data science de la division **Protection Sociale France et Internationale (PSFI) de Diot-Siaci**. Au carrefour des équipes commerciales, des gestionnaires métier et de la direction de la division, j'ai été amenée à concevoir et déployer des solutions analytiques diverses, depuis l'exploitation de données d'enquête classiques jusqu'à l'intégration d'un grand modèle de langage dans un outil destiné aux équipes. Cette transversalité a profondément orienté ma vision du métier : la valeur d'un projet data ou IA ne se mesure pas seulement à la rigueur de ses calculs ou à la sophistication de ses modèles, mais aussi à la capacité de ses résultats à être compris, appropriés et utilisés par ceux à qui ils sont destinés. Dans un environnement de courtage où les utilisateurs finaux ne sont que rarement des spécialistes de la donnée, cette exigence d'intelligibilité devient une contrainte structurante de la conception même des solutions.

Par souci de confidentialité et de respect des données clients, les noms d'entreprises et d'associations spécifiquement évoqués dans ce rapport ont été anonymisés, et les données présentées ont été soit anonymisées, soit remplacées par des exemples illustratifs.

À travers les missions qui m'ont été confiées, un constat structurel s'est progressivement dégagé : les indicateurs structurés tels que les scores de satisfaction, les moyennes statistiques ou les volumes agrégés offrent une mesure synthétique du réel, mais ne suffisent pas à en saisir la complexité. Ils indiquent *combien* sans expliquer *pourquoi*. Ils signalent l'existence d'une anomalie sans la qualifier. Pour répondre aux besoins opérationnels réels des équipes et des clients de la PSFI, il est devenu nécessaire de croiser ces données structurées avec des sources non structurées : verbatims libres, comporte-

ments multidimensionnels, signaux faibles. Cette articulation entre données structurées et non structurées, et la manière dont la data science et l’IA permettent de la rendre opérationnellement utile dans le contexte du courtage en santé prévoyance, constitue la problématique centrale de ce rapport :

Dans quelle mesure la data science, appliquée aux données structurées et non structurées, permet-elle d’améliorer la performance opérationnelle dans le secteur de la santé prévoyance ?

Pour y répondre, ce rapport s’organise en quatre parties. La **première partie** pose le cadre contextuel et conceptuel de la mission : présentation détaillée de Diot-Siaci et de la division PSFI, enjeux de la satisfaction client dans le secteur de la protection sociale, et apports respectifs des approches classiques de traitement du langage et des grands modèles de langage. Les **trois parties suivantes** restituent chacune une mission selon une structure commune. La **Mission 1** décrit l’analyse des comportements de non adhésion à une mutuelle collective portée par une association professionnelle cliente, restituée sous forme de tableaux de bord interactifs et de recommandations stratégiques. La **Mission 2** présente la conception d’une solution d’analyse sémantique de verbatims clients fondée sur le modèle de langage Mistral Large 2, intégrée dans une application Streamlit. La **Mission 3** expose la conception d’un système de détection automatisée de comportements atypiques chez les professionnels de santé conventionnés, combinant trois familles d’approches statistiques et un mécanisme de scoring de convergence. Une conclusion synthétisera les enseignements transversaux de cette année d’alternance et ouvrira sur les perspectives qu’elle a permis d’esquisser.

1. Contexte et enjeux

1.1. Présentation de Diot-Siaci et de l'offre PSFI

1.1.1. Le groupe Diot-Siaci

Diot-Siaci est un groupe multispécialiste de conseil et de courtage d'assurance et de réassurance, leader en France et en Europe, présent sur tous les continents avec des bureaux dans une quarantaine de pays. Né en 2022 du rapprochement de Diot et Siaci Saint-Honoré, le groupe s'est imposé comme un acteur incontournable du secteur assurantiel français. Avec plus de 8 000 collaborateurs, un chiffre d'affaires de 1,03 milliard d'euros et plus de 5 millions de personnes assurées, Diot-Siaci accompagne une clientèle variée allant des grandes entreprises aux PME, en passant par les professionnels et les particuliers. Il conçoit des solutions innovantes sur mesure aussi bien en assurances de personnes qu'en assurances de biens et de responsabilités, couvrant les domaines de l'IARD, du transport, de la responsabilité civile professionnelle, de la protection sociale et de la mobilité internationale.

1.1.2. L'offre Protection Sociale France et Internationale (PSFI)

Au sein du groupe, la division **Protection Sociale France et Internationale (PSFI)** constitue le périmètre dans lequel s'inscrit cette alternance. Elle accompagne les entreprises clientes dans la conception, la mise en place et le suivi de leurs contrats de protection sociale collective : complémentaire santé, prévoyance, retraite supplémentaire et mobilité internationale. Elle intervient auprès de grandes entreprises, d'associations et de structures intermédiaires, en assurant l'interface entre les assureurs, les employeurs et les assurés.

La PSFI se distingue par une approche orientée service : au delà de la négociation des contrats, elle assure un suivi opérationnel continu des populations assurées, incluant la gestion des adhésions, le traitement des réclamations et le pilotage de la satisfaction client. C'est dans ce cadre que s'inscrit naturellement la valorisation des données collectées auprès des assurés et des entreprises clientes, et donc le rôle structurant du pôle data science.

1.1.3. Le pôle data science et mon poste

Le pôle data science de la PSFI regroupe une équipe de **12 personnes**, organisée en deux sous équipes supervisées chacune par un manager. J'intègre la sous équipe directement rattachée à **Serigne FALL**, composée de 4 personnes dont moi même. Les

missions du pôle couvrent un large spectre : production de tableaux de bord à destination des équipes commerciales et métiers, automatisation des traitements de données, développement d’outils d’analyse et, plus récemment, intégration de l’intelligence artificielle générative dans les processus d’analyse client.

L’environnement technique du pôle repose sur un socle d’outils structurants : **Snowflake** pour le stockage et le traitement des données en cloud, **Tableau** pour la visualisation et la restitution, **Alteryx** pour la préparation et l’automatisation des données, et **Python** avec **Streamlit** pour le développement d’applications analytiques internes.

Dans ce cadre, j’occupe le poste de **data scientist en alternance**, au contact de plusieurs équipes : équipes commerciales, équipes métiers (gestionnaires, chargés de relation client) et direction de la PSFI. Cette transversalité m’a permis de comprendre les besoins opérationnels réels des différents interlocuteurs et d’y apporter des réponses concrètes à travers les missions décrites dans ce rapport.

1.2. La satisfaction client dans le secteur de la protection sociale

1.2.1. Les indicateurs de satisfaction

Dans le secteur de la protection sociale, la mesure de la satisfaction client repose sur plusieurs indicateurs complémentaires, dont trois sont au cœur des enquêtes administrées au sein de la PSFI :

- Le **NPS** (Net Promoter Score) mesure la propension des clients à recommander le service. Calculé comme la différence entre le pourcentage de promoteurs (note 9 à 10) et de détracteurs (note 0 à 6), c’est l’indicateur synthétique de référence pour évaluer la fidélité client.
- Le **CSAT** (Customer Satisfaction Score) mesure la satisfaction globale suite à une interaction spécifique. Particulièrement adapté aux enquêtes administrées immédiatement après un contact, il capte le ressenti à chaud de l’assuré.
- Le **CES** (Customer Effort Score) évalue le niveau d’effort fourni par le client pour obtenir une réponse ou résoudre un problème. Un CES élevé signale une complexité excessive dans le parcours client.

Ces indicateurs sont collectés via deux modalités d’enquêtes complémentaires. Les **enquêtes à chaud** sont administrées peu après une interaction : elles capturent le ressenti immédiat et permettent de détecter des irritants opérationnels en quasi temps réel. Les **enquêtes à froid** sont envoyées à distance de l’interaction, pour recueillir une évaluation plus réfléchie de l’expérience globale. La combinaison des deux approches offre une vision à la fois réactive et longitudinale de la satisfaction.

1.2.2. Les limites des données structurées et l’apport des verbatims

Si ces indicateurs offrent une mesure synthétique et comparable de la satisfaction, ils partagent une limite fondamentale : ils indiquent *combien* de clients sont satisfaits ou insatisfaits, mais n’expliquent pas *pourquoi*. Un score NPS ou CSAT est mesurable, mais il ne permet pas d’identifier les causes profondes d’insatisfaction ni de hiérarchiser les axes d’amélioration.

C’est pour dépasser cette limite que les enquêtes intègrent des questions ouvertes, dont les réponses, les **verbatim**s, constituent une source d’information qualitative complémentaire. Un verbatim exprime directement la voix du client avec ses propres mots : il peut révéler un irritant précis, une attente non satisfaite ou une satisfaction difficile à quantifier. Exploiter cette richesse de manière systématique et à grande échelle nécessite cependant des outils adaptés, que les méthodes manuelles ou les statistiques classiques ne permettent pas de fournir.

1.3. L’intelligence artificielle au service de l’analyse textuelle

1.3.1. Le traitement automatique du langage naturel

Le **NLP** (Natural Language Processing) désigne l’ensemble des techniques permettant à une machine d’analyser et de comprendre du texte. Appliqué à l’analyse de verbatims, il permet d’automatiser des tâches impossibles à réaliser manuellement à grande échelle : classification thématique, détection de sentiment, extraction d’entités.

Les approches classiques (représentation en sac de mots, pondération TF-IDF, modèles supervisés comme Naive Bayes ou SVM) sont rapides et interprétables, mais analysent les mots de manière indépendante sans capturer le contexte global d’une phrase. Elles montrent leurs limites face à des phénomènes linguistiques complexes comme le sarcasme, l’ironie ou les formulations ambiguës, fréquents dans les retours clients spontanés.

1.3.2. Les grands modèles de langage (LLM)

L’avènement des **grands modèles de langage** (LLM, Large Language Models), fondés sur l’architecture Transformer et le mécanisme d’attention (Vaswani et al., 2017), a transformé l’analyse de texte. Entraînés sur des corpus massifs, ces modèles capturent les relations contextuelles entre les mots à l’échelle de la phrase entière. Ils comprennent les nuances sémantiques, les implicites et les contradictions internes d’un texte, là où les modèles classiques échouent.

Dans le secteur assurantiel, l’intégration des LLM ouvre des perspectives nouvelles pour l’exploitation des données non structurées : analyse automatisée des retours clients

à grande échelle, détection de signaux faibles dans les verbatims, enrichissement des tableaux de bord avec une dimension qualitative. C’est précisément dans cette direction que s’inscrit l’un des axes stratégiques du pôle data science de la PSFI, et que se situe la Mission 2 décrite dans ce rapport. Les choix techniques concrets, modèle retenu, infrastructure, limites rencontrées, sont détaillés dans la partie correspondante.

2. Mission 1 : Analyse des comportements de non adhésion à une mutuelle collective

2.1. Contexte et objectifs de la mission

Cette première mission s'inscrit dans une démarche d'accompagnement commercial conduite par le pôle data science de Diot-Siaci auprès d'**une association professionnelle cliente**, proposant une mutuelle collective à ses membres. Malgré la mise à disposition d'une couverture santé négociée, un nombre important de membres éligibles ne souscrivait pas au contrat. Face à ce constat, l'équipe commerciale souhaitait comprendre les ressorts de cette non adhésion afin d'adapter sa stratégie de communication et d'acquisition.

L'enquête a été administrée auprès des membres et a recueilli **298 répondants**. Les données collectées portaient sur la connaissance du contrat, le profil démographique (âge, situation familiale), les raisons de non adhésion, la sensibilité tarifaire et les besoins exprimés en matière de garanties.

L'objectif opérationnel était double : identifier les freins prioritaires à l'adhésion, et restituer ces résultats de façon claire et actionnable à destination d'interlocuteurs non spécialistes de la donnée.

2.2. Facteurs facilitants et obstacles rencontrés

2.2.1. Facteurs facilitants

Plusieurs éléments ont favorisé le bon déroulement de cette mission. En premier lieu, la **qualité des données** : les données d'enquête étaient de bonne qualité globale, sans problèmes majeurs de valeurs manquantes ou d'incohérences structurelles, ce qui a permis de concentrer l'effort sur l'analyse plutôt que sur le nettoyage.

L'environnement technique du pôle a constitué un second facteur facilitant. La disponibilité d'Alteryx et de Tableau, outils déjà maîtrisés par l'équipe, a permis une prise en main rapide et une intégration fluide dans les processus existants.

Le facteur humain a également joué un rôle important. J'ai travaillé en étroite collaboration avec **un collègue du pôle** : cette collaboration m'a permis de bénéficier d'un cadrage précis des attentes, d'un retour continu sur les livrables et d'une meilleure compréhension des enjeux spécifiques du client.

2.2.2. Obstacles rencontrés

La principale difficulté de cette mission était d’ordre **méthodologique** plutôt que technique. Traduire des données d’enquête en recommandations actionnables pour un public commercial non spécialiste de la donnée a nécessité un effort important de vulgarisation et de mise en récit : il ne s’agissait pas seulement de produire des graphiques corrects, mais de construire un discours analytique cohérent, en hiérarchisant les messages et en les formulant dans le langage des métiers.

Enfin, l’absence de **retour formalisé de l’équipe commerciale** au moment de la rédaction de ce rapport ne permet pas encore de mesurer l’impact opérationnel des recommandations formulées.

2.3. Préparation et traitement des données avec Alteryx

La première étape de la mission a consisté en un travail de préparation des données brutes issues de l’enquête, réalisé sous **Alteryx**.

2.3.1. Nettoyage des données

Les données brutes étaient de bonne qualité globale. Un nettoyage standard a néanmoins été appliqué sous Alteryx : vérification de la cohérence des modalités, suppression des doublons éventuels et homogénéisation des formats avant chargement dans Tableau.

2.3.2. Transformations appliquées

Deux transformations principales ont été nécessaires pour préparer les données à l’analyse :

- **Séparation de colonnes** : certaines variables étaient concaténées dans une même colonne. Un traitement de découpage a été appliqué pour isoler chaque information dans une colonne dédiée, condition nécessaire à leur exploitation analytique.
- **Transformation en labels** : certaines questions de l’enquête étaient structurées de façon matricielle. Pour chaque type de soin, le répondant indiquait un niveau de priorité ou d’importance. Ces données, initialement codées sous forme numérique, ont été transformées en libellés explicites afin de les rendre directement lisibles dans les visualisations.

2.3.3. Justification du choix d’Alteryx

Le recours à Alteryx pour cette étape s’est imposé pour deux raisons principales. D’une part, l’outil est intégré dans l’environnement technique du pôle, ce qui garantit la

maintenabilité du workflow par l’équipe. D’autre part, son approche visuelle permet de documenter chaque transformation, rendant le traitement auditable et reproductible, un aspect essentiel dans un contexte de reporting récurrent.

Voir Annexe D pour une capture du workflow Alteryx et le détail des blocs utilisés. (A rajouter pour les versions finales)

Cette étape de préparation des données illustre concrètement les enseignements du M2 en matière de traitement de données : gestion des valeurs manquantes, recodage de variables et homogénéisation des formats sont des opérations fondamentales abordées dans les cours de traitement des données, ici appliquées dans un contexte opérationnel réel.

2.4. Construction des tableaux de bord sous Tableau

Une fois les données nettoyées, l’analyse descriptive a été restituée sous forme de tableaux de bord interactifs développés avec **Tableau Software**.

2.4.1. Indicateurs retenus

Les indicateurs ont été sélectionnés pour éclairer directement les décisions commerciales :

- **Vue d’ensemble** : sur 298 répondants, 53 connaissaient l’offre et 27 étaient adhérents, révélant un taux de conversion de 51% parmi les personnes informées et un vivier de 255 personnes intéressées par un régime optionnel mais non touchées par la communication.
- **Niveau de connaissance du contrat** : indicateur central, ventilé par profil, permettant de quantifier l’ampleur du déficit d’information.
- **Profil des répondants** : répartition par âge et situation familiale, afin de déterminer si le frein à l’adhésion est lié au profil ou à la visibilité du contrat.
- **Analyse des obstacles** : distinction entre frein structurel (multi assurance, mutuelle du conjoint), frein perceptif (sensibilité tarifaire) et inadéquation des garanties.
- **Sensibilité tarifaire** : distribution des tranches de prix acceptées, pour identifier la cohorte dominante prête à accepter un tarif plus élevé.
- **Satisfaction et NPS** : taux de promoteurs parmi les adhérents existants, utilisé comme levier argumentatif pour les recommandations.

2.4.2. Choix des visualisations

Chaque indicateur a fait l’objet d’un choix graphique adapté à la nature de la variable et au public cible :

- Des **KPI synthétiques** (298 répondants, 53 connaissent l’offre, 27 adhérents, 255 intéressés) ont été mis en avant en tête de dashboard pour offrir une lecture immédiate des ordres de grandeur.
- Les variables catégorielles (profil démographique, type de couverture actuelle) ont été représentées par des **graphiques en barres** facilitant la comparaison des proportions.
- La sensibilité tarifaire a été visualisée sous forme de **distribution par tranches**, permettant d’identifier la cohorte dominante prête à accepter un tarif plus élevé.
- Des **filtres interactifs** ont été intégrés pour permettre à l’équipe commerciale d’explorer les données par segment de manière autonome.

La lisibilité pour un public non technique a guidé l’ensemble des choix : palette de couleurs limitée, titres explicites, annotations directes, absence de jargon statistique dans les libellés.

Voir Annexe C pour des captures d’écran du tableau de bord Tableau restitué à l’équipe commerciale. (A rajouter pour les versions finales)

Ces choix graphiques s’appuient sur les principes de statistiques descriptives et de data visualisation acquis en M2 : adapter le type de représentation à la nature de la variable, éviter les biais visuels et hiérarchiser l’information selon le public cible sont des réflexes méthodologiques directement mobilisés ici.

2.5. Principaux enseignements et recommandations

L’analyse a fait émerger des résultats structurants, restitués dans une présentation à destination de l’équipe commerciale du client.

2.5.1. Frein numéro 1 : la méconnaissance du contrat

Le résultat le plus saillant est que **près de 80% des répondants ne connaissent pas le contrat proposé par l’association**. Parmi les 53 membres informés, 27 avaient adhéré, soit un taux de conversion de 51%. Ce chiffre démontre que le produit convainc quand il est connu : le problème n’est pas l’offre elle-même, mais sa visibilité. La communication, essentiellement interne à l’association et peu relayée par le bouche à oreille, ne touche pas l’essentiel des membres éligibles.

Par ailleurs, l’analyse des profils a montré que **les adhérents et les non adhérents présentent des caractéristiques très proches** (population majoritairement senior, en couple, au delà de 50 ans). Le frein à l’adhésion n’est donc pas lié au profil individuel, mais bien à la visibilité du contrat.

2.5.2. Frein numéro 2 : concurrence et perception du prix

Un second frein a été identifié, de nature plus structurelle. Une partie des non adhérents est déjà couverte par une mutuelle : 42% bénéficient de la mutuelle du conjoint (cible très difficile à reconvertir en raison du co financement patronal), tandis que 50% sont sous contrat individuel représentant un **vivier de conquête prioritaire**, les mutuelles collectives étant généralement plus compétitives que les contrats individuels.

Sur la sensibilité tarifaire, l'analyse révèle que le prix n'est pas un plafond absolu : la cohorte la plus importante (35%) se déclare prête à accepter un tarif plus élevé si le rapport qualité prix est clairement démontré. Seule une infime fraction juge les garanties inadaptées.

D'un point de vue analytique, cette mission a mobilisé les outils statistiques du M2 : analyse univariée des distributions, comparaison de profils par segmentation, et interprétation des taux de conversion. La démarche hypothético déductive, partir d'un constat pour identifier les causes via les données, est au cœur de la formation en économétrie et statistiques.

2.5.3. Recommandations formulées

Sur la base de ces enseignements, trois axes stratégiques ont été recommandés à l'équipe commerciale :

- **Communiquer massivement** : lancer des campagnes de notoriété pour transformer les 255 membres intéressés en prospects actifs, en s'appuyant sur des canaux plus larges que la communication interne.
- **Activer le parrainage** : capitaliser sur les 81% d'adhérents satisfaits des garanties en mettant en place un programme de recommandation ciblé vers le profil senior dominant.
- **Cibler les contrats individuels** : développer des argumentaires comparatifs prix garanties pour convaincre les 50% de non adhérents sous contrat individuel, segment le plus accessible à la reconversion.

La restitution de ces résultats a été formalisée dans un support PowerPoint destiné à l'équipe commerciale, structuré autour de trois messages clés : le diagnostic (ampleur de la méconnaissance), les segments prioritaires, et les leviers d'action recommandés.

3. Mission 2 : Analyse sémantique des verbatims clients par l’IA

3.1. Origine du besoin et contexte de la mission

Les enquêtes de satisfaction administrées par le pôle data science de Diot-Siaci produisent, en plus des indicateurs structurés (scores NPS, CSAT, réponses fermées), un volume important de réponses libres appelées **verbatim**s. Ces données non structurées constituent une source d’information stratégique majeure : elles expriment directement la voix du client, avec ses nuances, ses frustrations et ses satisfactions, là où les scores fermés ne donnent qu’une mesure agrégée.

Depuis un moment, les équipes métiers ainsi que le responsable du pôle data science cherchaient à exploiter ces verbatims de manière systématique et à les intégrer dans les restitutions clients, au même titre que les indicateurs quantitatifs. L’objectif était d’enrichir les tableaux de bord existants avec une dimension qualitative : comprendre *pourquoi* un score est bon ou mauvais, et identifier des signaux faibles que les données structurées ne captent pas.

La mission m’a été confiée avec une large autonomie : à partir de plusieurs bases de données de verbatims existantes, j’ai conçu et déployé de manière autonome l’ensemble de la solution, de la définition de l’approche technique jusqu’au livrable final, sous la supervision de mon tuteur entreprise.

Trois types d’enquêtes sont couverts par la solution :

- **Enquête à chaud assurés** : administrée peu après un contact avec le service client, elle capte le ressenti immédiat de l’assuré suite à un appel.
- **Enquête à froid assurés** : administrée à distance de l’interaction, elle recueille un retour plus réflexif sur l’expérience globale de l’assuré.
- **Enquête à froid entreprises** : destinée aux interlocuteurs RH ou responsables de la protection sociale au sein des entreprises clientes, elle porte sur la relation de service dans le courtage en assurance collective.

3.2. Facteurs facilitants et obstacles rencontrés

3.2.1. Facteurs facilitants

Cette mission a bénéficié de plusieurs conditions favorables. L’infrastructure Snowflake, déjà en place au sein du pôle, a constitué un socle technique solide. Bien que cette

plateforme fût nouvelle pour moi, les conseils de mon tuteur, maîtrisant l’environnement Snowflake, combinés à une étude approfondie de la documentation et de la littérature technique disponible, m’ont permis de monter en compétences rapidement et de concevoir une solution robuste dans ce nouvel environnement.

La **supervision de mon tuteur Serigne FALL** a joué un rôle structurant tout au long de la mission. Bien que la conception et le développement aient été menés de manière autonome, ses retours réguliers ont permis de valider les choix techniques et de s’assurer que les livrables répondaient aux attentes des équipes métiers. La taxonomie thématique a notamment été co validée avec lui et les métiers avant déploiement, garantissant son adéquation avec les réalités opérationnelles du secteur.

3.2.2. Obstacles rencontrés

Les principales difficultés rencontrées étaient de deux ordres.

La première tenait à la **nature non structurée des données**. Contrairement aux données tabulaires classiques, les verbatims sont des textes libres, hétérogènes dans leur forme, leur longueur et leur registre. Cette absence de structure impose de concevoir une solution capable de traiter des entrées très variables, du mot unique à plusieurs phrases, sans pouvoir s’appuyer sur des colonnes ou des formats prédéfinis. La gestion des encodages multiples, des abréviations, des fautes de frappe et du jargon métier assurantiel a représenté un défi technique constant tout au long du développement.

La seconde difficulté était liée à la **variabilité des volumes de données**. La solution devait traiter plusieurs bases de données distinctes, chacune de taille différente selon le type d’enquête et la période concernée. Le traitement par lots via l’opérateur LATERAL FLATTEN a permis d’optimiser les appels à Snowflake Cortex, mais la taille de lot fixe de 500 verbatims retenue s’est révélée sous optimale selon les volumes : trop grande pour de petites bases, potentiellement insuffisante pour de très grands volumes.

3.3. Pourquoi le NLP classique ne suffisait pas

La première approche envisagée reposait sur des méthodes de **NLP classique en Python** : analyse de sentiment via des bibliothèques comme VADER ou TextBlob, classification par sac de mots ou TF-IDF couplé à un classifieur supervisé (Naive Bayes, SVM). Ces approches, abordées dans les cours de machine learning du M2, sont rapides à mettre en œuvre et ne nécessitent pas d’infrastructure lourde.

Cependant, elles partagent une limite fondamentale : elles analysent les mots de manière **indépendante**, sans capturer le contexte global d’une phrase. Or les verbatims clients sont des textes rédigés librement, souvent depuis un smartphone, avec des abrégia-

tions, des fautes de frappe, des tournures familières et du jargon métier assurantiel non reconnu par les dictionnaires génériques. Dans ce contexte, les modèles NLP classiques échouent sur plusieurs dimensions essentielles :

- **La gestion des fautes d’orthographe et formulations non standard** : un terme mal orthographié ou une abréviation phonétique suffit à rendre le mot non reconnu par le modèle, faussant ainsi la classification.
- **L’incapacité à détecter le sarcasme et l’ironie** : un modèle basé sur des mots isolés détecte les mots positifs et négatifs indépendamment, sans percevoir la contradiction entre le ton apparent et le sens réel d’une phrase. Un verbatim ironique sera systématiquement mal classifié.
- **L’absence de compréhension du sens** : le NLP classique ne comprend pas le contexte, les implicites ni les nuances sémantiques. Il est incapable de distinguer deux phrases structurellement similaires mais de sens opposés.

Ces limites ont conduit à écarter le NLP classique au profit d’une approche fondée sur un **grand modèle de langage (LLM)**, capable de comprendre le contexte global d’une phrase, les implicites, le sarcasme et les nuances sémantiques. Ce choix s’appuie directement sur les enseignements du M2 en machine learning avancé : la compréhension des limites structurelles des modèles supervisés classiques face à des données non structurées et contextuelles, acquise en cours, a guidé la décision de recourir à un LLM. Les Transformers, fondés sur le mécanisme d’attention (Vaswani et al., 2017), capturent les dépendances contextuelles entre les mots à l’échelle de la phrase entière, une capacité inaccessible aux approches classiques et décisive pour l’analyse de verbatims clients en langage naturel.

3.4. Architecture technique de la solution

3.4.1. Choix technologiques

La solution s’appuie sur trois briques technologiques complémentaires :

- **Snowflake** : plateforme cloud de stockage et de traitement des données déjà utilisée par le pôle. Les verbatims y sont stockés et les appels au modèle de langage y sont exécutés directement via Snowflake Cortex, ce qui évite tout transfert de données sensibles vers un service externe.
- **Snowflake Cortex et Mistral Large 2** : service d’IA intégré à Snowflake permettant d’appeler des LLM directement en SQL via la fonction `SNOWFLAKE.CORTEX.COMPLETE()`. Parmi les modèles disponibles dans l’environnement Snowflake de Diot-Siaci, seul **Mis-**

tral Large 2 offrait les performances nécessaires pour une classification thématique et sentimentale fiable sur des verbatims en français avec jargon métier.

- **Streamlit** : framework Python permettant de créer des applications web interactives, accessibles aux équipes métiers sans compétences techniques.

Le flux de traitement suit la logique suivante : le fichier de verbatims est chargé dans l’application Streamlit, les textes sont envoyés à Snowflake Cortex qui appelle Mistral Large 2, les résultats (thème, sous catégorie, sentiment) sont renvoyés et affichés dans l’interface avec des visualisations interactives.

Voir Annexe A pour le schéma détaillé de l’architecture technique de la solution. (A rajouter pour les versions finales)

3.4.2. Ingestion et préparation des fichiers

L’application accepte les formats CSV (avec détection automatique du séparateur et de l’encodage parmi UTF-8, Latin-1, CP1252, UTF-8-sig) et Excel (.xlsx, .xls). Les noms de colonnes sont normalisés automatiquement (suppression des accents, mise en minuscules, remplacement des espaces). Les verbatims vides sont filtrés avant traitement. L’utilisateur sélectionne manuellement la colonne identifiant et la colonne texte, ce qui rend l’outil compatible avec n’importe quelle structure de fichier.

3.5. Conception des prompts et taxonomie thématique

3.5.1. Approche par prompt engineering

Le cœur de la solution repose sur la conception de **prompts structurés** soumis à Mistral Large 2 via Snowflake Cortex. Chaque verbatim est analysé en deux temps : d’abord la détection du thème, puis simultanément la sous catégorie et le sentiment, le tout renvoyé au format JSON pour faciliter le traitement.

Les prompts ont été construits selon plusieurs principes :

- **Rôle explicite** : chaque prompt commence par définir le rôle du modèle, ce qui conditionne le registre et le niveau de précision attendus.
- **Liste fermée de valeurs** : les thèmes et sous catégories autorisés sont listés explicitement, avec la consigne de ne retourner qu’une seule valeur parmi cette liste, garantissant des sorties structurées et directement exploitables.
- **Règles de gestion des cas limites** : textes vides, incompréhensibles ou hors périmètre sont traités avec des règles explicites (retourner « Autre » ou « Null »).

- **Détection du sarcasme et de l’ironie** : les prompts de sentiment intègrent des instructions spécifiques pour détecter ces phénomènes linguistiques. Un ton positif contredisant une situation négative est classifié *Négatif*.

Les prompts ont été validés par le tuteur ainsi que le métier avant déploiement, garantissant leur adéquation avec les réalités opérationnelles du secteur.

3.5.2. Taxonomie thématique par type d’enquête

La taxonomie a été conçue de manière **modulaire** : chaque type d’enquête dispose de ses propres thèmes et sous catégories, adaptés à la nature des interactions concernées.

Enquête à chaud assurés : 7 thèmes sans sous catégorie :

- Délais et réactivité
- Clarté et qualité de la réponse
- Qualité relationnelle
- Effort et complexité du parcours
- Résolution au premier contact
- Besoin de rappel
- Satisfaction et recommandation

Enquête à froid entreprises : 5 thèmes avec sous catégories :

- Conformité du contrat et adéquation aux attentes (*Conformité réglementaire ; Adéquation des garanties*)
- Qualité, réactivité et accessibilité du contact (*Temps de réponse ; Accessibilité téléphonique ; Fiabilité des informations*)
- Gestion administrative et prestations (*Affiliations et radiations ; Documents salariés ; Anomalies de remboursement*)
- Espaces digitaux et expérience utilisateur (*Accessibilité et ergonomie ; Fiabilité technique*)
- Accompagnement et conseil (*Qualité de l’accompagnement ; Pertinence du conseil*)

Enquête à froid assurés : 7 thèmes avec sous catégories :

- Analyse des devis (*Comparatif des offres ; Clarté tarifaire*)
- Délais et qualité des réponses (*Réactivité ; Exactitude*)
- Remboursements (*Délai de traitement ; Montant accordé*)

- Site, application, espace client (*Facilité d’utilisation ; Disponibilité technique*)
- Suivi et mise à jour du dossier personnel (*Actualisation des informations ; Transparence du suivi*)
- Mise à disposition de la carte de tiers payant (*Délai d’obtention ; Fonctionnalité en réseau*)
- Service client et satisfaction globale (*Qualité de l’écoute ; Efficacité de résolution*)

3.6. Analyse de sentiment

Quatre polarités sont détectées pour chaque verbatim :

- **Positif** : satisfaction explicite, félicitations, retour favorable.
- **Négatif** : insatisfaction, critique, sarcasme ou ironie détectée.
- **Neutre** : texte factuel, informatif, ou mentions telles que « RAS » ou « rien à signaler ».
- **Mixte** : texte exprimant simultanément des aspects positifs et négatifs de manière équilibrée.

Un mécanisme de **normalisation post traitement** a été implémenté en Python pour corriger les cas où Mistral retournerait une réponse légèrement différente du format attendu. Cette fonction mappe la réponse brute du modèle vers l’une des quatre polarités standard, garantissant la cohérence des données dans les visualisations finales.

3.7. Livrable : l’application Streamlit

3.7.1. Fonctionnalités de l’application

L’application développée sous Streamlit s’articule autour de trois onglets :

- **Onglet Résultats** : tableau interactif affichant pour chaque verbatim son identifiant, son texte, le thème détecté, la sous catégorie (pour les enquêtes à froid) et le sentiment. Une barre de recherche permet de filtrer les verbatims par mot clé.
- **Onglet Statistiques dynamiques** : visualisations interactives générées avec Plotly (camembert de distribution des thèmes, graphique en barres des sentiments, barplot thème par sentiment empilé, et top 10 des sous catégories). Des filtres permettent de restreindre l’analyse à un ou plusieurs thèmes et sentiments. Des métriques synthétiques sont affichées : taux positif, négatif, neutre, mixte, longueur moyenne des verbatims, ainsi qu’un classement des cinq thèmes générant le plus de plaintes et le plus de satisfactions.

- **Onglet Export** : téléchargement des résultats au format CSV, Excel (avec feuilles séparées pour les statistiques et les tops plaintes et satisfactions) ou JSON.

L’application intègre également un **mode test** dans la barre latérale, permettant de soumettre un verbatim individuel pour vérifier en temps réel la classification, sans charger un fichier complet.

3.7.2. Choix de conception orientés utilisateur

Plusieurs décisions de conception ont été prises pour adapter l’outil à des utilisateurs non techniques :

- **Sélection du type d’enquête en premier** : l’utilisateur choisit le type d’enquête avant de charger son fichier, ce qui oriente automatiquement la taxonomie thématique appliquée.
- **Détection automatique du format** : séparateur CSV, encodage et feuille Excel sont détectés sans intervention de l’utilisateur.
- **Mode test et mode complet** : un mode test limité aux 50 premiers verbatims permet de valider rapidement la qualité de l’analyse avant de lancer le traitement sur l’ensemble du fichier.
- **Traitement par lots** : le traitement individuel de chaque verbatim générerait une latence trop importante pour des fichiers volumineux. Le passage à un traitement par lots via LATERAL FLATTEN a permis de regrouper plusieurs verbatims en une seule requête Snowflake, réduisant ainsi le nombre d’appels au modèle. La taille de lot de 500 verbatims a été retenue comme valeur par défaut, offrant un bon équilibre entre temps de traitement et stabilité des requêtes sur les volumes observés en pratique. Une amélioration envisageable serait un batch dynamique adapté à la taille du fichier, ou un traitement parallèle via ThreadPoolExecutor, qui permettrait de traiter plusieurs lots simultanément sur de grands volumes.

Voir Annexe B pour les captures d’écran de l’application Streamlit et Annexe E pour la taxonomie complète des thèmes. (A rajouter pour les versions finales)

3.8. Résultats et apports pour les métiers

La solution développée a été mise à disposition des équipes métiers à l’issue de la mission. Les premiers retours ont confirmé le bon fonctionnement de l’application et sa prise en main intuitive par des utilisateurs non techniques. L’outil répond à l’objectif initial : permettre aux équipes de disposer d’une analyse thématique et sentimentale des

verbatim de manière autonome et rapide, sans intervention systématique du pôle data science.

Sur le plan analytique, la solution apporte une dimension qualitative jusqu’alors absente des restitutions. Là où les scores NPS et CSAT indiquaient le niveau de satisfaction, l’analyse des verbatims permet désormais d’en comprendre les causes, d’identifier les thématiques les plus génératrices d’insatisfaction et de détecter des signaux faibles non capturés par les questions fermées. Cette complémentarité entre données structurées et non structurées constitue la valeur ajoutée principale de la mission.

3.9. Limites et perspectives

Bien que la solution apporte une valeur ajoutée significative par rapport aux approches NLP classiques, plusieurs limites ont été identifiées :

- **Verbatims très courts ou vagues** : des réponses telles que « Bien » ou « OK » sont systématiquement classifiées Neutre faute de contexte suffisant. Ces verbatims, nombreux dans les enquêtes à chaud, réduisent la richesse de l’analyse sans qu’il soit possible d’en extraire davantage.
- **Taxonomie prédéfinie** : la liste fermée de thèmes garantit des sorties exploitables, mais implique qu’un verbatim hors périmètre soit classifié « Autre », perdant ainsi toute valeur analytique. Une taxonomie trop rigide peut également mal capturer des signaux émergents non anticipés lors de sa conception.
- **Verbatims hors sujet** : la liberté offerte par les questions ouvertes a conduit certains répondants à exprimer des sujets sans lien avec l’enquête, introduisant un bruit dans l’analyse. Ce constat plaide pour un meilleur cadrage des questions ouvertes en amont, voire le recours à des questions semi fermées.
- **Absence d’évaluation quantitative** : faute de jeu de données annoté manuellement, l’évaluation de la qualité des classifications reste qualitative. Il n’a pas été possible de calculer des métriques formelles telles que la précision, le rappel ou le F1 score pour valider objectivement les performances du modèle.

En perspective, plusieurs évolutions sont envisageables : la généralisation de l’outil à d’autres types d’enquêtes en paramétrant dynamiquement la taxonomie, l’intégration des résultats directement dans les dashboards Tableau pour une restitution en temps réel, l’enrichissement du système par une analyse longitudinale des sentiments permettant de suivre l’évolution de la satisfaction client dans le temps, et l’optimisation du traitement par lots via un batch dynamique ou un traitement parallèle pour mieux absorber des volumes variables.

4. Mission 3 : Détection automatisée de comportements atypiques sur les décomptes de remboursement santé

4.1. Contexte et enjeux de la mission

La détection des comportements atypiques dans l'assurance santé constitue un enjeu financier et opérationnel majeur pour les assureurs et leurs courtiers. Surfacturations, actes inhabituellement nombreux, ruptures d'activité, concentration anormale des actes sur un nombre limité de patients : autant de signaux qui peuvent traduire des comportements à risque de la part de certains professionnels de santé conventionnés. Dans ce contexte, le pôle data science de Diot-Siaci a pour mission d'outiller les équipes métier afin qu'elles puissent identifier rapidement les décomptes de remboursement les plus suspects parmi des volumes ingérables manuellement.

La mission qui m'a été confiée s'inscrit dans cette démarche. Au sein d'une équipe travaillant sur l'ensemble de la chaîne de détection, je suis intervenue plus particulièrement sur la **famille d'approches dite Fréquence**, dédiée à l'analyse temporelle et volumique des activités des professionnels de santé conventionnés. Mon périmètre couvrait à la fois la conception et l'implémentation des méthodes statistiques de cette famille, ainsi qu'une contribution méthodologique transversale : la conception d'un **scoring de convergence** permettant de croiser les résultats des différentes familles d'approches pour prioriser les cas les plus suspects.

La méthode a été développée avec une logique d'extension progressive. La **version livrée et actuellement en production porte sur le périmètre des opticiens**, secteur où les comportements atypiques sont statistiquement les plus marqués, avec des développements en cours pour étendre la couverture à l'ensemble des professionnels de santé (pharmaciens, médecins, kinésithérapeutes, etc.).

4.2. Facteurs facilitants et obstacles rencontrés

4.2.1. Facteurs facilitants

Cette mission a bénéficié de plusieurs conditions favorables. Une **forte autonomie** m'a été accordée sur le périmètre Fréquence, permettant de construire la démarche méthodologique de bout en bout, depuis le choix des méthodes statistiques jusqu'à la conception du livrable final. L'écosystème technique du pôle, déjà mature (Alteryx pour l'orchestration des workflows et Python pour les calculs avancés), a constitué un socle robuste sur

lequel s’appuyer.

Le travail en équipe avec les collègues responsables des autres familles d’approches a également joué un rôle structurant : les échanges réguliers ont permis d’aligner les méthodes et de concevoir un système global cohérent.

4.2.2. Obstacles rencontrés

La principale difficulté de cette mission n’a pas été technique mais conceptuelle et de **vulgarisation**. Le défi central était de transformer des analyses statistiques complexes (Z scores, variations temporelles, ratios) en un livrable simple, lisible et directement actionnable par des équipes métier non spécialistes de la donnée. Sans cette traduction, l’outil le plus rigoureux statistiquement reste inutilisé.

Un second obstacle tenait à **l’absence de vérité terrain annotée**. À ce stade, le pôle ne disposait pas d’un jeu de données labellisé permettant de mesurer objectivement la performance du système. L’évaluation est donc restée qualitative, basée sur la cohérence des cas remontés et les retours des équipes métier. Cette absence a également contraint la définition des seuils des différentes méthodes statistiques : ils ont dû être fixés par raisonnement méthodologique et analyse de la distribution des données observées, sans optimisation formelle.

4.3. Pourquoi une approche multi méthodes est nécessaire

L’approche la plus intuitive pour détecter les comportements atypiques serait d’appliquer une méthode statistique unique : par exemple, repérer tous les professionnels de santé dont l’activité dépasse un seuil donné. Cette approche présente toutefois deux limites majeures.

D’une part, elle génère un **volume très élevé de faux positifs**. Un professionnel de santé peut dépasser un seuil pour des raisons parfaitement légitimes (forte affluence saisonnière, ouverture d’un nouveau cabinet, campagne de santé publique). D’autre part, elle ne couvre qu’une seule dimension de l’atypicité : un comportement à risque peut se manifester par des montants normaux mais une fréquence anormale, ou par une concentration inhabituelle des actes sans excès apparent en volume absolu.

Les comportements atypiques étant des phénomènes multi dimensionnels, le pôle a retenu une approche fondée sur la **validation croisée** : combiner plusieurs familles d’approches regardant les données sous des angles différents, puis prioriser les cas flagués simultanément par plusieurs familles. L’analogie qui guide cette démarche est celle du diagnostic médical : un seul symptôme peut être trompeur, mais plusieurs symptômes convergents permettent d’établir un diagnostic fiable.

4.4. La famille Fréquence : trois méthodes statistiques complémentaires

La famille Fréquence, dont j’ai assuré la conception et l’implémentation, analyse la dimension temporelle et volumique de l’activité des professionnels de santé. Elle repose sur trois méthodes statistiques complémentaires, chacune permettant de détecter un type spécifique d’anomalie.

4.4.1. Méthode 1 : Détection statistique par Z score

Cette première méthode consiste à comparer l’activité observée d’un professionnel à son comportement historique. Pour chaque professionnel, la **moyenne** de son activité est d’abord calculée afin de représenter son niveau habituel sur la période étudiée. Ensuite, l’**écart type** est calculé pour mesurer la variabilité normale de cette activité.

Le **Z score** est alors calculé pour chaque observation :

$$Z = \frac{x - \mu}{\sigma}$$

où x désigne la valeur observée, μ la moyenne historique du professionnel et σ son écart type. Cette mesure indique le nombre d’écarts types séparant la valeur observée de la moyenne.

Un seuil de $Z > 2$ a été retenu pour identifier les observations atypiques. Ce seuil est couramment utilisé en statistique inférentielle car, dans le cadre d’une distribution approximativement normale, il permet d’isoler les observations significativement supérieures au comportement habituel (environ 2,5% des observations sous l’hypothèse de normalité).

Objectif : détecter les professionnels de santé dont le niveau d’activité est anormalement élevé par rapport à leur propre historique.

4.4.2. Méthode 2 : Analyse des variations temporelles

Cette deuxième méthode vise à détecter les **ruptures de comportement dans le temps** en comparant l’activité d’un mois à celle du mois précédent. Le taux de variation mensuelle est calculé pour chaque professionnel, et plusieurs paliers d’interprétation ont été définis : Le taux de variation mensuelle est calculé pour chaque professionnel selon la formule suivante :

$$V_t = \frac{A_t - A_{t-1}}{A_{t-1}} \times 100$$

où A_t désigne l’activité observée au mois t et A_{t-1} celle du mois précédent. Cette mesure exprime la variation en pourcentage d’un mois à l’autre.

- Variation $\leq 50\%$: comportement considéré comme normal.
- Variation entre 50% et 200% : comportement atypique.
- Variation supérieure à 200% : comportement fortement atypique.
- Variation supérieure à 400% : comportement critique.

Ces seuils ont été définis à partir de l’analyse de la distribution des variations observées sur l’historique disponible. Ils permettent de distinguer les fluctuations normales (saisonnalité, variations ponctuelles) des ruptures significatives qui peuvent traduire un changement de comportement nécessitant investigation.

Objectif : identifier les augmentations brutales d’activité pouvant traduire un changement de comportement.

4.4.3. Méthode 3 : Analyse du ratio actes par patient

Cette troisième méthode évalue la **concentration de l’activité** d’un professionnel en rapportant le nombre d’actes réalisés au nombre de patients pris en charge. Le ratio est défini comme suit :

$$R = \frac{N_{\text{actes}}}{N_{\text{patients}}}$$

où N_{actes} désigne le nombre total d’actes réalisés par le professionnel sur la période, et N_{patients} le nombre de patients distincts pris en charge sur cette même période. Un ratio élevé traduit une concentration importante d’actes sur un nombre limité de patients, ce qui peut constituer un indicateur de comportement atypique : multiplication des actes par patient, sur prescription, ou pratiques commerciales inhabituelles.

À titre indicatif, un **ratio supérieur à 3** a été retenu comme seuil de déclenchement d’une analyse plus approfondie. Ce seuil constitue un repère métier, défini en concertation avec les équipes, et doit être interprété en fonction du contexte d’activité spécifique à chaque type de professionnel de santé.

Objectif : détecter les professionnels de santé dont le volume d’actes par patient est inhabituellement élevé.

4.4.4. Complémentarité des trois méthodes

Les trois méthodes de la famille Fréquence sont complémentaires et permettent d’appréhender différentes dimensions du comportement temporel et volumique des professionnels de santé :

- Le **Z score** mesure le caractère anormal du niveau d’activité par rapport à l’historique propre du professionnel.

- L’analyse de **variation temporelle** met en évidence les ruptures d’activité d’un mois à l’autre.
- Le **ratio actes par patient** évalue la concentration de l’activité sur les patients.

Le croisement de ces trois indicateurs au sein de la famille Fréquence renforce déjà la fiabilité de la détection. Mais c’est leur articulation avec les deux autres familles d’approches (Distance et Montant) qui constitue le cœur du dispositif global.

4.5. Vue d’ensemble des trois familles d’approches

L’architecture globale de détection repose sur trois familles d’approches complémentaires, conçues par l’équipe :

- La famille **Distance** compare chaque professionnel à ses pairs (même catégorie, même zone géographique) afin de détecter ceux qui se démarquent anormalement de leur groupe de référence.
- La famille **Montant** analyse la distribution statistique des remboursements du professionnel (moyenne, médiane, percentile 95) afin de détecter les décomptes aberrants par rapport à son propre historique.
- La famille **Fréquence**, sur laquelle j’ai travaillé, analyse la dimension temporelle et volumique (Z score, variations temporelles, ratio actes par patient).

Chaque famille produit, pour chaque professionnel, une liste de décomptes flagués comme atypiques selon ses propres critères.

4.6. Innovation méthodologique : le scoring de convergence

4.6.1. Le constat à l’origine de la démarche

Sans traitement supplémentaire, l’addition brute des résultats des trois familles d’approches est inexploitable en pratique. Un seul professionnel peut présenter plusieurs centaines de décomptes flagués au total, certains par une seule famille, d’autres par plusieurs. Les équipes métier se retrouvent alors face à une liste trop volumineuse pour être traitée manuellement, sans hiérarchisation claire des cas prioritaires.

4.6.2. L’intuition centrale

L’idée que j’ai conçue pour répondre à ce problème consiste à **croiser les listes produites par les trois familles** pour identifier les décomptes désignés simultanément par plusieurs d’entre elles. Un décompte flagué par les trois familles à la fois est suspect pour trois raisons indépendantes : il est probablement révélateur d’un comportement

réellement atypique. À l’inverse, un décompte flagué par une seule famille peut résulter d’un faux positif isolé.

4.6.3. Pondération exponentielle

Pour traduire cette intuition en score quantitatif, j’ai retenu une **pondération exponentielle**. Le score attribué à un décompte d est défini comme :

$$S(d) = k^2$$

où $k \in \{1, 2, 3\}$ désigne le nombre de familles d’approches ayant flagué le décompte d . Ce choix se traduit par les valeurs suivantes :

- Décompte flagué par 1 famille : $S(d) = 1$ point
- Décompte flagué par 2 familles : $S(d) = 4$ points
- Décompte flagué par 3 familles : $S(d) = 9$ points

Le choix d’une pondération exponentielle plutôt que linéaire est méthodologiquement fondé. La convergence de plusieurs signaux indépendants ne constitue pas une simple addition de suspicion, elle représente un **saut qualitatif**. Trois signaux convergents fournissent une certitude bien supérieure à la somme de trois signaux isolés. La pondération exponentielle reflète cette différence de nature.

4.6.4. Normalisation par la taille du professionnel

Le score brut d’un professionnel p est obtenu en sommant les scores individuels de tous ses décomptes flagués. Pour éviter de pénaliser ou d’avantager mécaniquement les professionnels selon leur volume total d’activité, ce score est **normalisé** par le nombre total de décomptes du professionnel sur la période :

$$S_{\text{norm}}(p) = \frac{1}{N_p} \sum_{d \in D_p} S(d)$$

où D_p désigne l’ensemble des décomptes flagués du professionnel p , N_p le nombre total de décomptes émis par p sur la période étudiée, et $S(d)$ le score du décompte d défini précédemment. Cette normalisation permet de comparer équitablement des professionnels de tailles très différentes.

4.7. Architecture technique de la solution

La solution s’appuie sur deux briques technologiques articulées dans un workflow unifié :

- **Alteryx** orchestre le workflow global : nettoyage des données, calculs statistiques préliminaires pour chacune des trois familles (Z scores, variations temporelles, ratios, statistiques inter et intra professionnels), agrégations par professionnel.
- **Python**, intégré au workflow Alteryx via l’outil Python, implémente le scoring de convergence : croisement des listes de décomptes flagués par chaque famille, calcul du score pondéré, catégorisation en niveaux de priorité.

Voir Annexe F pour le schéma d’architecture de la solution. (A rajouter pour les versions finales)

Le choix d’intégrer Python directement dans Alteryx plutôt que de développer une solution Python autonome répond à une exigence de **maintenabilité par l’équipe** : le workflow Alteryx reste auditable et reproductible, tout en bénéficiant de la flexibilité algorithmique de Python pour les traitements avancés que sont le croisement des listes et le calcul du scoring.

4.8. Du score technique au livrable métier

La traduction du score technique en livrable opérationnel a constitué l’enjeu central et la principale difficulté de cette mission. Pour chaque professionnel, le livrable final fournit :

- Un **niveau de priorité** classé sur quatre paliers immédiatement lisibles : CRITIQUE, HAUTE, MOYENNE, FAIBLE.
- La **liste précise des décomptes à investiguer en priorité**, avec pour chacun le détail des familles d’approches qui l’ont flagué.
- Des informations contextuelles permettant à l’équipe métier de comprendre rapidement pourquoi tel décompte ressort.

Un soin particulier a été apporté à la **suppression du jargon statistique** dans le livrable final : aucun Z score, ratio brut ou score numérique technique n’apparaît dans la sortie utilisée par les équipes métier. La traduction en quatre niveaux qualitatifs assure une appropriation immédiate par des interlocuteurs non spécialistes de la donnée. Cette approche s’inscrit directement dans la logique de l’enseignement du M2 sur la communication des résultats : la valeur d’une analyse ne se réalise qu’au moment où elle est comprise et utilisée par son destinataire.

4.9. Résultats et apports pour les métiers

La solution est aujourd’hui en production sur le périmètre opticiens. À titre d’illustration, sur un professionnel de santé disposant d’environ 1000 décomptes sur la période d’analyse, le système identifie typiquement 2 décomptes classés CRITIQUE (flagués par les

trois familles simultanément), une dizaine classés HAUTE, et restitue le reste en niveau MOYENNE ou FAIBLE.

L’apport opérationnel est double. D’une part, le ratio de **réduction du volume** à investiguer est de l’ordre de **plusieurs centaines pour un** : les équipes passent d’une liste inexploitable de centaines de décomptes potentiellement suspects à une liste actionnable de quelques cas hautement prioritaires. D’autre part, l’utilisation effective de l’outil par les métiers témoigne de la **confiance gagnée** : la lisibilité du livrable et la clarté du raisonnement sous jacent ont permis une adoption réelle, là où des outils plus sophistiqués mais opaques restent souvent inutilisés.

Voir Annexe G pour un exemple anonymisé de livrable par professionnel avec niveaux de priorité. (A rajouter pour les versions finales)

4.10. Limites et perspectives

Plusieurs limites ont été identifiées et constituent autant de pistes d’amélioration.

- **Absence d’évaluation quantitative formelle** : sans jeu de données annoté, la performance du système ne peut être mesurée par des métriques classiques (précision, rappel, F1 score). L’évaluation reste qualitative et basée sur les retours métiers.
- **Seuils empiriques** : les seuils retenus pour chaque méthode statistique ($Z > 2$, paliers de variation à 50%, 200%, 400%, ratio > 3) ainsi que la pondération exponentielle (1, 4, 9) du scoring sont méthodologiquement justifiés mais empiriques. Une optimisation rigoureuse nécessiterait précisément la base annotée qui fait défaut.
- **Périmètre actuel limité aux opticiens** : bien que la méthode soit générique par construction, sa version en production ne couvre aujourd’hui que ce secteur. L’extension aux pharmaciens, médecins et autres professionnels de santé constitue le chantier en cours.
- **Risque résiduel de faux négatifs** : certains comportements atypiques subtils (variations restant dans la norme, ratios légèrement décalés) peuvent échapper à la détection. La méthode est calibrée pour minimiser les faux positifs tout en assumant ce risque résiduel.

Plusieurs perspectives sont envisagées : la généralisation progressive à l’ensemble des professionnels de santé, la constitution d’un jeu de données annoté permettant à terme une évaluation quantitative et l’optimisation des seuils et des poids, l’évolution éventuelle vers un modèle de machine learning supervisé une fois la base annotée constituée, et l’intégration directe des résultats dans les dashboards Tableau pour une restitution temps réel aux équipes métier.

Cette mission a mobilisé l'ensemble des compétences du M2 en statistique appliquée (analyse de distributions, Z scores, détection d'anomalies), en programmation Python et en conception méthodologique. Elle a également constitué un exercice concret sur la dimension la plus exigeante du métier de data scientist en entreprise : faire en sorte qu'une analyse statistique rigoureuse devienne un outil métier réellement utilisé.

Conclusion

Ce rapport est parti d’une question qui semblait simple en apparence : *dans quelle mesure la data science, appliquée aux données structurées et non structurées, permet-elle d’améliorer la performance opérationnelle dans le secteur de la santé prévoyance ?* À l’issue des trois missions menées au sein du pôle data science de la PSFI de Diot-Siaci, plusieurs éléments de réponse se dégagent.

Les trois projets restitués dans ce rapport partagent une logique commune : ils montrent que la valeur opérationnelle d’une analyse ne tient pas tant à la sophistication des modèles mobilisés qu’à la capacité de la solution à **réduire la complexité** pour ses utilisateurs finaux. L’analyse de la non adhésion à une mutuelle collective (Mission 1) a transformé les données brutes d’une enquête de 298 répondants en trois recommandations stratégiques claires pour l’équipe commerciale, en hiérarchisant les freins identifiés et en proposant des leviers d’action concrets. L’analyse sémantique des verbatims par intelligence artificielle générative (Mission 2) a doté les équipes métier d’un outil leur permettant d’exploiter en autonomie une matière qualitative jusqu’alors peu valorisée, comblant l’écart entre les scores de satisfaction et la compréhension de leurs causes. La détection automatisée des comportements atypiques chez les professionnels de santé (Mission 3) a posé les bases méthodologiques d’un système de priorisation permettant aux équipes métier de cibler précisément les décomptes à investiguer, là où le volume rendait toute analyse manuelle impraticable. Dans les trois cas, l’enjeu central était identique : rendre exploitable ce qui, à l’état brut, ne l’était pas.

Cette articulation entre rigueur technique et utilité opérationnelle constitue le principal enseignement transversal de cette année. **Un outil, aussi performant soit il, ne crée de valeur que s’il est compris, accepté et utilisé par ceux à qui il est destiné.** Cette exigence d’intelligibilité a structuré l’ensemble de mes choix méthodologiques : catégorisation en niveaux de priorité lisibles plutôt qu’en scores statistiques, suppression du jargon technique dans les livrables finaux, interfaces utilisateurs guidées étape par étape, restitution sous forme de tableaux de bord interactifs accessibles sans formation préalable. Ce travail de traduction, souvent invisible dans la valorisation académique de la data science, s’est révélé être la dimension la plus exigeante et la plus déterminante du métier.

Cette année a également permis de constater à la fois la **puissance et les limites des grands modèles de langage** dans un contexte professionnel. Mistral Large 2, utilisé dans la Mission 2 pour l’analyse des verbatims, a fait franchir un saut qualitatif à l’exploitation des données non structurées, en captant des nuances que les approches NLP classiques (sac

de mots, TF-IDF, classifieurs supervisés) ne pouvaient atteindre. Cependant, sa mise en production a soulevé des défis spécifiques : choix de la taxonomie thématique, conception de prompts robustes, gestion des cas limites (verbatim très courts, hors sujet), équilibre entre temps de traitement et stabilité des requêtes. Plus largement, la question de la **confiance dans les sorties d'un modèle génératif** reste un chantier ouvert, qui suppose une vigilance permanente et une co validation systématique avec les équipes métier.

Plusieurs limites doivent par ailleurs être assumées. La principale est commune aux Missions 2 et 3 : **l'absence de jeu de données annoté** ne permet pas d'évaluer quantitativement les performances des solutions développées (précision, rappel, F1 score). L'évaluation reste qualitative, fondée sur la cohérence des résultats produits et les retours des équipes métier. La constitution progressive de tels jeux annotés constitue une perspective majeure pour les années à venir, qui permettrait à terme l'optimisation des taxonomies, des seuils et des pondérations, ainsi que l'évolution éventuelle vers des modèles supervisés véritablement industriels. Par ailleurs, la Mission 1 attend encore les retours formalisés de l'équipe commerciale qui permettront de mesurer l'impact concret des recommandations, et la Mission 3, aujourd'hui en production sur le périmètre des opticiens, a vocation à s'étendre à l'ensemble des professionnels de santé conventionnés (pharmaciens, médecins, kinésithérapeutes). La généralisation des approches d'IA générative à d'autres types de données qualitatives (réclamations écrites, courriers clients, transcriptions d'appels) ouvre enfin un champ d'application particulièrement prometteur pour les prochains travaux du pôle.

Sur le plan personnel, cette alternance a constitué une expérience formatrice à plusieurs titres. Elle m'a permis d'éprouver, dans un contexte professionnel réel, les compétences développées au cours du **Master 2 Econometrics and Statistics — Track Data Science** : statistiques descriptives et inférentielles, machine learning, programmation Python, et plus récemment intelligence artificielle générative. Elle a également été l'occasion de m'approprier de nouveaux outils que je ne maîtrisais pas en début d'alternance, en particulier Snowflake et son service Cortex, dont la prise en main rapide a été rendue possible par l'appui de mon tuteur et un travail soutenu de documentation technique. Au delà des outils, travailler au carrefour des équipes commerciales, des gestionnaires métier et de la direction de la PSFI m'a appris à **traduire en permanence** : traduire un besoin métier en problème statistique, traduire un résultat analytique en recommandation business, traduire un score technique en action concrète.

Plus fondamentalement, cette année a confirmé mon souhait de poursuivre ma carrière à l'intersection de la data science, de l'intelligence artificielle et des enjeux métier. Au delà des outils et des modèles, ce qui m'anime aujourd'hui, c'est cette conviction : **la donnée**

ne devient véritablement utile qu’au moment où elle est mise au service d’une décision, d’un usage, d’une personne. C’est dans cette articulation entre la rigueur du chiffre et l’exigence du sens que se joue, à mon sens, le rôle d’une data scientist aujourd’hui : non seulement produire de la connaissance, mais en garantir l’appropriation durable au sein des organisations.

Bibliographie

- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., et Polosukhin, I. (2017). *Attention is all you need*. Advances in Neural Information Processing Systems, 30.
- Reichheld, F. F. (2003). The One Number You Need to Grow. *Harvard Business Review*, 81(12), 46 à 54.
- Aggarwal, C. C. (2017). *Outlier Analysis* (2^e édition). Springer.
- Chandola, V., Banerjee, A., et Kumar, V. (2009). Anomaly detection : A survey. *ACM Computing Surveys*, 41(3), 1 à 58.
- Mistral AI (2024). *Mistral Large 2, Documentation technique*. <https://docs.mistral.ai/>
- Snowflake Inc. (2024). *Snowflake Cortex, LLM Functions Reference*. <https://docs.snowflake.com/en/user-guide/snowflake-cortex/>
- Streamlit (2024). *Streamlit Documentation*. <https://docs.streamlit.io/>
- Alteryx (2024). *Alteryx Designer Documentation*. <https://help.alteryx.com/>
- DREES (2024). *La complémentaire santé en France : acteurs, bénéficiaires, garanties*. Ministère des Solidarités et de la Santé.
- ACPR (2024). *Rapport annuel sur le secteur assurantiel français*. Autorité de Contrôle Prudentiel et de Résolution.

Annexes

Note sur la confidentialité : Les données présentées dans les annexes de ce rapport ont été **intégralement anonymisées** ou **remplacées par des données fictives** construites à des fins d'illustration uniquement. Aucune information permettant d'identifier un client, un assuré ou un professionnel de santé réel n'apparaît dans ce document. Les noms de clients, identifiants de décomptes, verbatims et tout autre élément à caractère personnel ou sensible ont été modifiés ou inventés dans le respect des obligations de confidentialité applicables (RGPD, secret professionnel, secret des affaires).

Annexe A : Schéma d'architecture technique de la solution d'analyse des verbatims (Mission 2)

Annexe B : Captures d'écran de l'application Streamlit d'analyse sémantique des verbatims (Mission 2, statistiques agrégées)

Annexe C : Captures d'écran du tableau de bord Tableau de restitution de l'enquête (Mission 1, données anonymisées)

Annexe D : Vue du workflow Alteryx de préparation des données d'enquête (Mission 1)

Annexe E : Tableau complet des thèmes et sous catégories de la taxonomie utilisée pour la classification des verbatims (Mission 2)


Annexe F : Schéma du procédé de scoring de convergence et vue du workflow Alteryx associé (Mission 3)

Annexe G : Exemple anonymisé de livrable par professionnel de santé avec niveaux de priorité (Mission 3, données fictives)

Annexe H : Exemples fictifs de verbatims et leur classification par le modèle Mistral Large 2 (Mission 2)

Annexe A : Architecture technique de la solution d'analyse des verbatims (Mission 2)

Le schéma ci-dessous restitue le flux complet de traitement, depuis le chargement du fichier de verbatims par l'utilisateur métier jusqu'à la restitution des résultats enrichis. Le point structurant de cette architecture est que les verbatims ne quittent jamais l'environnement Snowflake du groupe : l'appel au modèle de langage s'exécute à l'intérieur de la plateforme, via le service Cortex, ce qui écarte tout transfert de données personnelles vers un service tiers.



Précisions techniques. L'application accepte les formats CSV, avec détection automatique du séparateur et de l'encodage parmi UTF-8, Latin-1, CP1252 et UTF-8-sig, ainsi que les formats Excel `.xlsx` et `.xls`. Les noms de colonnes sont normalisés automatiquement (suppression des accents, passage en minuscules, remplacement des espaces) et les verbatims vides sont filtrés avant traitement. Le regroupement des verbatims par lots de 500 s'appuie sur l'opérateur `LATERAL FLATTEN`, qui permet de soumettre plusieurs textes en une seule requête et réduit ainsi le nombre d'appels au modèle.

Annexe B : Captures d'écran de l'application Streamlit (Mission 2)

Les captures ci-dessous documentent le parcours complet de l'utilisateur métier dans l'application, depuis le dépôt du fichier jusqu'à la lecture des résultats. Aucun verbatim n'y apparaît : seules les statistiques agrégées produites par l'analyse sont visibles, ce qui écarte tout risque de réidentification d'un assuré.

i Informations

Instructions:

1. Sélectionnez le type d'enquête
2. Téléchargez votre fichier
3. Sélectionnez les colonnes ID et texte
4. Lancez l'analyse
5. Dans l'onglet Statistiques:
 - utilisez les filtres manuels sous le camembert

🔧 Test rapide

Type de test:

☒ Sentiment seulement

☐ Thématique + Sentiment

Analyse de Verbatims

Application web pour analyser les verbatims afin de faciliter leur utilisation pour des visualisations. Selon le type d'enquête : **Enquête à chaud Assurés**, **Enquête à froid Entreprise** ou **Enquête à froid Assurés**, l'application trouve les thèmes et sentiments.

Type d'enquête :

☒ Enquête à chaud Assurés

☐ Enquête à froid Entreprise

☐ Enquête à froid Assurés


📁 Dépose ton fichier CSV ou Excel

📁 Drag and drop file here
Limit 200MB per file • CSV, XLSX, XLS

Browse files


Page d'entrée : sélection du type d'enquête, dépôt du fichier et choix des colonnes à analyser.

La page d'entrée matérialise le choix de conception central de la mission : l'utilisateur ne paramètre ni le modèle, ni le prompt, ni la taxonomie. Il déclare seulement le type d'enquête, ce qui suffit à sélectionner en arrière-plan la grille d'analyse appropriée. Cette contrainte volontaire est ce qui rend l'outil utilisable sans compétence technique, au prix d'une souplesse réduite.




Onglet Statistiques : filtres manuels et indicateurs de synthèse.

Le taux d'erreur affiché mesure la part de verbatims pour lesquels la sortie du modèle n'a pas pu être exploitée, faute de JSON valide ou de correspondance avec la taxonomie. Il constitue le premier signal de fiabilité consulté par l'utilisateur : c'est lui qui indique si les distributions présentées ensuite portent bien sur l'ensemble du corpus déposé.



Distribution des thèmes issus de la taxonomie fermée.




Croisement thème × sentiment.

Lecture des deux derniers graphiques. Le premier hiérarchise les thèmes par fréquence de citation, le second par charge négative. Ces deux hiérarchies ne coïncident pas

nécessairement : un thème peut être très cité tout en concentrant peu d'insatisfaction, et inversement. C'est leur confrontation, et non la seule distribution des thèmes, qui oriente la priorisation des actions correctives par les équipes relation client.

Annexe C : Tableau de bord de restitution de l'enquête (Mission 1)

Le tableau de bord restitué à l'équipe commerciale organise sur une seule page les six analyses issues de l'enquête. Toute mention permettant d'identifier le client a été retirée des captures. Les repères numérotés de la vue d'ensemble renvoient aux vues détaillées présentées ensuite.





Vue d'ensemble du tableau de bord et repères de lecture.





Repère 0 — Bandeau de filtres et indicateurs de cadrage.

Les quatre filtres agissent simultanément sur l'ensemble des vues. C'est ce qui permet à l'équipe commerciale de recalculer chaque indicateur sur un sous-ensemble de répondants sans solliciter le pôle analytique, et donc de prolonger l'analyse au-delà de la livraison.





Repères 1 et 2 — Structure démographique des répondants.

Ces deux vues conditionnent la lecture de toutes les suivantes : la concentration des répondants sur les tranches d'âge élevées oriente mécaniquement les besoins exprimés par poste de soins, et interdit de lire les résultats comme représentatifs de l'ensemble de la population couverte.



Repères 3 et 6 — Taux d'adhésion observé et répartition territoriale.

La forte proportion de non-adhérents constitue le point de départ de l'analyse des comportements de non-adhésion. La vue régionale s'appuie sur la variable géographique fiabilisée en amont dans le flux de préparation, détaillé en Annexe D.





Repères 4 et 5 — Recours aux soins déclaré et attentes de renfort par poste.

Lecture croisée. Ces deux vues partagent volontairement la même liste de postes de soins, dans le même ordre, afin de rendre l’écart directement lisible. Les postes où un recours fréquent coexiste avec une demande de renfort élevée sont ceux sur lesquels l’ajustement de l’offre a le meilleur rendement commercial ; ceux où un recours faible coexiste avec une demande forte relèvent davantage d’un défaut de connaissance de la couverture existante que d’un défaut de couverture.

Annexe D : Workflow Alteryx de préparation des données d’enquête (Mission 1)

Le flux de préparation transforme les réponses brutes du formulaire en une table analytique exploitable par le tableau de bord. Le schéma ci-dessous en restitue la logique ; la capture qui suit documente le bloc le plus déterminant pour la qualité du résultat, la fiabilisation de la variable géographique.





Extrait du flux implémenté : règle de repli sur la variable département.

Précisions techniques. La question géographique de l’enquête étant ouverte, les réponses collectées mêlent noms de communes, codes postaux et noms de régions, avec des graphies hétérogènes. Le flux applique d’abord une normalisation (suppression des espaces parasites, passage en majuscules, extraction par expression régulière des seuls caractères numériques du département déclaré), puis tente un rapprochement successif sur trois référentiels, du plus précis au moins précis. Le département finalement retenu est celui issu du premier rapprochement abouti ; les enregistrements restés non appariés sont explicitement marqués « Non renseigné » plutôt qu’imputés. Ce choix réduit la couverture géographique affichée mais garantit qu’aucune localisation n’est fabriquée, ce qui est la condition pour que la vue régionale du tableau de bord soit opposable.

Annexe E : Taxonomie complète des thèmes et sous-catégories (Mission 2)

La taxonomie a été conçue de manière modulaire : chaque type d'enquête dispose de ses propres thèmes et sous-catégories, adaptés à la nature des interactions concernées. Elle a été co-validée avec le tuteur entreprise et les équipes métier avant déploiement. Les listes ci-dessous sont celles effectivement transmises au modèle dans les prompts, sous forme de listes fermées de valeurs autorisées.

Thème	Sous-catégories
<i>Enquête à chaud — assurés</i> 7 thèmes, sans sous-catégorie	
Délais et réactivité	—
Clarté et qualité de la réponse	—
Qualité relationnelle	—
Effort et complexité du parcours	—
Résolution au premier contact	—
Besoin de rappel	—
Satisfaction et recommandation	—
<i>Enquête à froid — entreprises</i> 5 thèmes avec sous-catégories	
Conformité du contrat et adéquation aux attentes	Conformité réglementaire ; Adéquation des garanties
Qualité, réactivité et accessibilité du contact	Temps de réponse ; Accessibilité téléphonique ; Fiabilité des informations
Gestion administrative et prestations	Affiliations et radiations ; Documents salariés ; Anomalies de remboursement
Espaces digitaux et expérience utilisateur	Accessibilité et ergonomie ; Fiabilité technique
Accompagnement et conseil	Qualité de l'accompagnement ; Pertinence du conseil
<i>Enquête à froid — assurés</i> 7 thèmes avec sous-catégories	
Analyse des devis	Comparatif des offres ; Clarté tarifaire
Délais et qualité des réponses	Réactivité ; Exactitude

(suite page suivante)

Thème	Sous-catégories
Remboursements	Délai de traitement ; Montant accordé
Site, application, espace client	Facilité d’utilisation ; Disponibilité technique
Suivi et mise à jour du dossier personnel	Actualisation des informations ; Transparence du suivi
Mise à disposition de la carte de tiers payant	Délai d’obtention ; Fonctionnalité en réseau
Service client et satisfaction globale	Qualité de l’écoute ; Efficacité de résolution


Valeurs de sortie complémentaires. Deux valeurs hors taxonomie sont prévues par les règles de gestion des cas limites intégrées aux prompts : la valeur *Autre*, retournée lorsque le verbatim ne relève d’aucun thème de la liste, et la valeur *Null*, retournée lorsque le texte est vide ou incompréhensible. Le suivi de la proportion de verbatims classés *Autre* constitue un indicateur direct de l’obsolescence de la taxonomie et justifierait, à terme, une révision périodique de celle-ci.

Polarités de sentiment. Quatre polarités sont détectées, indépendamment du type d’enquête : *Positif* (satisfaction explicite, félicitations, retour favorable), *Négatif* (insatisfaction, critique, sarcasme ou ironie détectée), *Neutre* (texte factuel, informatif, ou mentions telles que « RAS ») et *Mixte* (texte exprimant simultanément des aspects positifs et négatifs de manière équilibrée). Une fonction de normalisation implémentée en Python mappe la réponse brute du modèle vers l’une de ces quatre valeurs standard, garantissant la cohérence des données dans les visualisations finales.

Annexe F : Scoring de convergence et workflow associé (Mission 3)

F.1 — Principe de fonctionnement

Le schéma ci-dessous restitue la logique de croisement des trois familles d'approches. Chaque famille produit indépendamment une liste de décomptes signalés selon ses propres critères. Le croisement de ces listes permet d'identifier les décomptes désignés simultanément par plusieurs familles, et d'attribuer à chacun un score reflétant le nombre de signaux convergents.



Formalisation. Le score attribué à un décompte d est défini par

$$S(d) = k^2, \quad k \in \{1, 2, 3\},$$

où k désigne le nombre de familles d'approches ayant signalé le décompte d . Le score brut d'un professionnel p est obtenu en sommant les scores individuels de ses décomptes signalés, puis normalisé par son volume total d'activité sur la période :

$$S_{\text{norm}}(p) = \frac{1}{N_p} \sum_{d \in D_p} S(d),$$


où D_p désigne l'ensemble des décomptes signalés du professionnel p et N_p le nombre total de décomptes qu'il a émis sur la période étudiée.

Convergence observée	$S(d)$	Interprétation retenue
Signalé par 1 famille	1	Signal isolé, potentiellement un faux positif
Signalé par 2 familles	4	Convergence partielle, à surveiller
Signalé par 3 familles	9	Convergence complète, investigation prioritaire

Le choix d'une pondération exponentielle plutôt que linéaire est méthodologiquement fondé : la convergence de plusieurs signaux indépendants ne constitue pas une simple addition de suspicion, elle représente un saut qualitatif. Trois signaux convergents fournissent une certitude supérieure à la somme de trois signaux isolés, et la pondération exponentielle traduit cette différence de nature.


F.2 — Implémentation sous Alteryx

Le schéma ci-dessous restitue l’organisation générale de la macro qui met en œuvre le procédé décrit en F.1. Les captures qui suivent en documentent les deux blocs déterminants : la famille d’approches traitée dans le cadre de cette mission, puis la construction du classement transmis aux équipes.




Les trois familles d’approches cohabitent dans la macro. Les travaux présentés dans ce

mémoire portent sur la famille Fréquence, signalée en couleur, ainsi que sur le score de convergence, qui agrège les signaux produits par l'ensemble des familles disponibles.



Extrait du flux implémenté : les trois approches de la famille Fréquence.

Les trois approches. L'approche par ratio rapporte l'activité facturée au nombre de patients reçus sur la période, et signale les professionnels dont ce rapport s'écarte de la norme observée. L'approche temporelle mesure la variation d'activité d'un mois à l'autre pour un même professionnel, et distingue plusieurs niveaux de variation selon l'ampleur de l'écart. L'approche par écart standardisé situe chaque professionnel par rapport à la dispersion observée sur l'ensemble du portefeuille. Ces trois lectures sont volontairement redondantes : un même décompte peut être signalé par plusieurs d'entre elles, et c'est précisément cette redondance qui fonde la logique de convergence exposée en F.1.



Extrait du flux implémenté : construction et classement du score.

Du signal au classement. La normalisation par le volume d'activité est visible ici sous la forme d'un rapport entre le nombre de décomptes signalés et le nombre de décomptes

examinés : elle neutralise l'effet de taille, de sorte qu'un professionnel très actif ne se retrouve pas mécaniquement en tête du classement. Les valeurs manquantes sont ramenées à zéro plutôt qu'écartées, afin qu'un professionnel non concerné par une famille d'approches reste présent dans le classement. Le score obtenu est enfin trié par ordre décroissant pour produire le niveau de priorité restitué aux équipes.

Annexe G : Exemple de livrable par professionnel de santé (Mission 3)

L’exemple ci-dessous reproduit la structure du livrable transmis aux équipes métier. **L’ensemble des données est fictif** : identifiants, volumes et dates ont été construits à des fins d’illustration uniquement. Il illustre le cas d’un opticien disposant d’environ un millier de décomptes sur la période d’analyse.

G.1 — Synthèse par professionnel

Élément	Valeur
Identifiant professionnel	PS-OPT-4172 (<i>fictif</i>)
Catégorie	Opticien conventionné
Période analysée	Janvier — Décembre
Volume total de décomptes	1 043
Décomptes signalés, toutes familles confondues	187
Décomptes en priorité Critique	2
Décomptes en priorité Haute	11
Décomptes en priorité Moyenne	46
Décomptes en priorité Faible	128
Volume à investiguer en priorité	13 décomptes sur 1 043

La réduction du volume à traiter manuellement est ici de l’ordre de quatre-vingts pour un si l’on rapporte les treize cas prioritaires au volume total de décomptes, et de plus de quatorze pour un si on les rapporte à la liste brute des décomptes signalés par au moins une famille. C’est cette hiérarchisation, et non la détection elle-même, qui rend l’exploitation manuelle possible.

G.2 — Détail des décomptes prioritaires

Décompte	Date	Dist.	Mont.	Fréq.	Priorité
DEC-2024-08831	14/03	●	●	●	Critique
DEC-2024-09427	06/09	●	●	●	Critique
DEC-2024-08655	02/03	●	●	—	Haute
DEC-2024-08902	21/03	—	●	●	Haute
DEC-2024-09106	17/06	●	—	●	Haute
DEC-2024-09318	28/08	●	●	—	Haute
DEC-2024-09455	11/09	—	●	●	Haute
(... 6 autres décomptes en priorité Haute)					

Lecture. Les colonnes *Dist.*, *Mont.* et *Fréq.* indiquent quelles familles d’approches ont signalé le décompte. Un décompte signalé par les trois familles simultanément est classé *Critique* : il est suspect pour trois raisons méthodologiquement indépendantes.

G.3 — Informations contextuelles jointes

Pour chaque décompte prioritaire, le livrable fournit également les éléments de contexte permettant à l’équipe métier de comprendre immédiatement l’origine du signalement, sans recourir à une lecture technique :

Information	Exemple (fictif)
Motif principal du signalement	Activité mensuelle très supérieure au niveau habituel du professionnel
Contexte temporel	Mois concerné en forte rupture par rapport au mois précédent
Contexte de concentration	Nombre d’actes par patient nettement au-dessus du repère métier
Comparaison aux pairs	Position atypique par rapport aux opticiens de la même zone

Aucune valeur numérique technique — Z-score, taux de variation, ratio brut ou score de convergence — n’apparaît dans le livrable remis aux équipes. Cette décision de conception, discutée en section 4.8, conditionne l’appropriation de l’outil par des interlocuteurs non spécialistes de la donnée.

Annexe H : Exemples de verbatims et classifications obtenues (Mission 2)

Les verbatims présentés ci-dessous sont **entièrement fictifs**. Ils ont été rédigés pour illustrer les capacités et les limites du modèle, en reproduisant les caractéristiques observées sur les données réelles : formulations spontanées, abréviations, fautes de frappe et registre familier. Les cas 5 à 8 ont été spécifiquement construits pour documenter les difficultés analysées en section 3.9.

#	Verbatim (fictif)	Thème détecté	Sentiment
1	« La conseillère a pris le temps de tout m’expliquer, très agréable, j’ai raccroché en ayant compris. »	Qualité relationnelle	Positif
2	« 3 semaines pour un remboursement de lunette c bcp trop long franchement »	Remboursements <i>Délai de traitement</i>	Négatif
3	« Rapide au tel mais on m’a redonné une info fausse, j’ai dû rappeler deux fois. »	Délais et qualité des réponses <i>Exactitude</i>	Mixte
4	« Impossible de me connecter à l’espace client depuis la mise à jour de l’appli. »	Site, application, espace client <i>Disponibilité technique</i>	Négatif
5	« Bravo, six appels et toujours aucune réponse, service au top vraiment. »	Effort et complexité du parcours	Négatif
<i>Cas d’ironie. Un modèle fondé sur des mots isolés relèverait « bravo » et « au top » et classerait ce verbatim Positif. Le modèle de langage identifie la contradiction entre le registre employé et la situation décrite.</i>			
6	« Bien »	Satisfaction et recommandation	Neutre
<i>Verbatim trop court pour être exploité. Faute de contexte, la classification se rabat sur Neutre : ces réponses, nombreuses dans les enquêtes à chaud, réduisent la richesse de l’analyse sans qu’il soit possible d’en extraire davantage.</i>			

(suite page suivante)

#	Verbatim (fictif)	Thème détecté	Sentiment
7	« RAS »	Satisfaction et recommandation	Neutre
<i>Mention factuelle explicitement traitée par les règles de gestion des cas limites intégrées aux prompts.</i>			
8	« Le parking de l’agence est mal indiqué, j’ai tourné vingt minutes. »	Autre	Négatif
<i>Verbatim hors périmètre de l’enquête. La liberté offerte par les questions ouvertes conduit certains répondants à exprimer des sujets sans lien avec la relation de service mesurée. Classé « Autre », ce retour perd toute valeur analytique — ce qui plaide pour un meilleur cadrage des questions ouvertes en amont.</i>			

Lecture d’ensemble. Les quatre premiers cas illustrent le fonctionnement nominal de la solution, y compris sur des textes comportant abréviations et fautes de frappe, que les approches classiques de traitement du langage échouent à interpréter. Le cinquième cas documente l’apport décisif du modèle de langage sur les phénomènes de sarcasme et d’ironie. Les trois derniers cas circonscrivent au contraire les limites structurelles de la solution, analysées en section 3.9 : la pauvreté informationnelle des verbatims très courts, et la perte d’information induite par une taxonomie fermée face aux retours hors périmètre.